Actividad #11

Machine Learning Roadmap, Data Forecasting

- Nombre 1:
- Nombre 2:
- Nombre 3:
- Fecha:
- Reposiroty: https://github.com/vasanza/SSE
- Refrence: https://github.com/vasanza/Matlab_Code/tree/main
- Dataset: Open Energy Data Initiative (OEDI)
- Photovoltaic Data Acquisition (PVDAQ) Public Datasets

Table of Contents

Descripción:

Objetivos:

Raw data

- Enfocarnos en la prediccion de datos "**Data Forecasting**"
- Determinar el periodo de tiempo que se desea hacer forecasting
- Determinar las variables de entrada (input) y de salida (output) de un sistema de caja negra

Preprocessing

- Remover valores NAN, outlier (hampel filter), etc.

Feature Extraction

- Variables or caracteristicas estadisticos en el tiempo de esas variables

Otros

- Utilizar matriz de correlacion para eliminar variables o caracteristicas redundantes
- Dividir el data en 70% (training_data) y 30% (testing_data)
- Utilizar el toolbox **"regressionLearner"** de Matlab
- Seleccionar el mejor modelo de Data Forecasting basado en el RMSE
- Utilizar el mejor modelo para hacer el testing en el codigo principal (main)

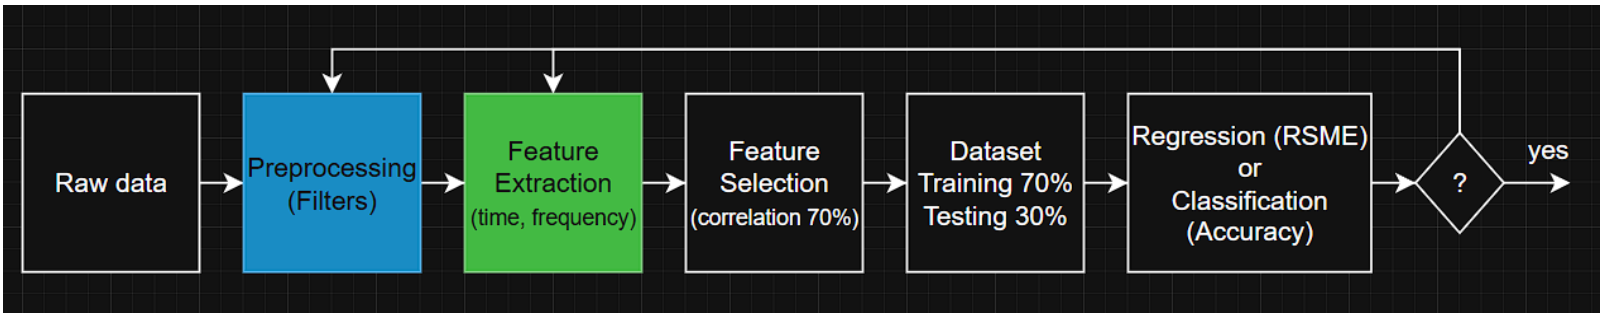

Tipo de Dataset a utilizar:

- Cada columna representa una variable y cada fila representa una muestra (frecuencia de mestreo constante)
- La primera columna es el TimeStamp. Ejemplo: 'dd-MMM-yyyy HH:mm:ss.SSS'
- El arhivo debe estar en formato **.csv**, si es otro formato de debera convertir a .csv. Ejemplo: si es **.parqet**, se lo convierte con esta pagina https://table.studio/convert/parquet/to/csv
- Si existen multiples archivos .csv, estos se deberan colocar en la carpeta data, siempre que esten relacionadas a un mismo sistema. **Ejemplo de regresion**: consumo_enero_2025.csv, consumo_febrero_2025.csv, etc. **Ejemplo de clasificacion**: consumo_casa_enero_2025.csv, sonsumo_escuela_enero_2025.csv, etc.

	measured_...	inv_string0...	inv_string0...	inv_string0...	inv_string0...	inv_string0...
	Datetime	Number	Number	Number	Number	Number
1	measured_on	inv_string01...	inv_string01...	inv_string01...	inv_string01...	inv_string01...
2	2018-12-29...	0.0	0.0	123.891	0.0	0.0
3	2018-12-29...	0.0	0.0	123.875	0.0	0.0
4	2018-12-29...	0.0	0.0	121.844	0.0	0.0
5	2018-12-30...	0.0	0.0	122.75	0.0	0.0
6	2018-12-30...	0.0	0.0	121.672	0.0	0.0
7	2018-12-31...	0.0	0.0	123.688	0.0	0.0

Copia la actividad en tu respaldo

```
%Configuracion de carpeta ./src para librerias
addpath(genpath('./src'));

% Definir rutas
miRespaldo = 'C:\Desktop\SSE_vic';  %<========
repositorio = 'C:\Desktop\SSE\2025';%<========

if true
    % repositorio -> respaldo
```

```
    git_sse(miRespaldo)
else
    % Mombre de la carpeta de la Actividad en el repositorio
    nombreCarpeta = string(split(cd, filesep));
    nombreCarpeta = nombreCarpeta(end) % Nombre de la carpeta
    % Regresar al repositorio
    cd(fullfile(repositorio,nombreCarpeta))
end
```

Desarrollo de la Actividad

Configuración de carpeta ./src para librerias y ./data para el raw data

```
clear % Borrar variables en el workspace y libera memoria RAM
clc % Limpia el Command Window
addpath(genpath('./src')); %librerias
datapath = fullfile('./data/');%raw data
```

Paso 1: Raw Data

Buscar nombres de archivos .csv en ./data

```
filename = FindCSV(datapath)
```

```
filename = struct with fields:
       name: '2105_inv01_data.csv'
     folder: 'C:\Users\victo\Desktop\SSE\2025\ACTIVIDAD11\data'
       date: '20-Jun-2025 19:15:47'
      bytes: 18694812
      isdir: 0
    datenum: 7.3979e+05
```

```
maxFiles = size(filename,1)
```

```
maxFiles = 1
```

Cargar automaticamente todos los archivos csv desde ./data

```
allData = [];
for i=1:maxFiles
    nameFile = filename(i).name;
    pathFile = strcat(datapath, nameFile);
    rawData = fLoad_dataset(pathFile);
    allData = [allData; rawData];
end
```

```
Warning: Column headers from the file were modified to make them valid MATLAB identifiers before creating
variable names for the table. The original column headers are saved in the VariableDescriptions property.
Set 'VariableNamingRule' to 'preserve' to use the original column headers as table variable names.
```

```
clear rawData nameFile filename;

%Seleccionar cuantas muestras queremos usar en esta actividad
maxSamples = size(allData,1);
```

```
samples = 8760;
%Visualizar propiedad de los archivos CSV
allData.Properties
```

```
ans =
  TableProperties with properties:

            Description: ''
               UserData: []
         DimensionNames: {'Row'  'Variables'}
          VariableNames: {1×6 cell}
    VariableDescriptions: {1×6 cell}
          VariableUnits: {}
      VariableContinuity: []
                RowNames: {}
        CustomProperties: No custom properties are set.
      Use addprop and rmprop to modify CustomProperties.
```

Extraer y graficar las variables

```
% Extraer el TimeStamp
t = datetime(allData.measured_on);
% Extraer el resto de variables
VariableNames = allData.Properties.VariableNames'
```

```
VariableNames = 6×1 cell
'measured_on'
'inv_string01_ac_output__kwh__inv_150164'
'inv_string01_ac_output__power_factor__inv_150165'
'inv_string01_ac_voltage__v__inv_150163'
'inv_string01_dc_voltage__v__inv_150162'
'inv_string01_temperature__c__inv_150166'
```

Identificar el periodo de muestreo del Raw Data

```
% Revisar el dataset
allData(1:4,:) %el periodo de sampleo es (15min)
```

```
ans = 4×6 table
```

...

	measured_on	inv_string01_ac_output__kwh__inv_150164
1	2019-02-12 10:...	0
2	2019-02-12 11:...	3.0210
3	2019-02-12 11:...	4.6650
4	2019-02-12 11:...	4.7250

```
%para hacer forecasting, definir un tiempo o step de prediccion
step = 4; %Representa un tiempo de prediccion (15min x step = 1h)
```

Inputs_Variables

```
% inv_string01_ac_output__kwh__inv_150164
pw_in = allData{:,VariableNames(2)}; % Variable de la columan 2
```

```
pw_in = pw_in(1:samples - step); % Limitar el numero de muestras

% inv_string01_ac_output__power_factor__inv_150165
pf_in = allData{:,VariableNames(3)};% Variable de la columan 3
pf_in = pf_in(1:samples - step); % Limitar el numero de muestras

% inv_string01_ac_voltage__v__inv_150163
vac_in = allData{:,VariableNames(4)};% Variable de la columan 4
vac_in = vac_in(1:samples - step); % Limitar el numero de muestras

% inv_string01_dc_voltage__v__inv_150162
vdc_in = allData{:,VariableNames(5)};% Variable de la columan 5
vdc_in = vdc_in(1:samples - step); % Limitar el numero de muestras

% inv_string01_temperature__c__inv_150166
temp_in = allData{:,VariableNames(6)};% Variable de la columan 6
temp_in = temp_in(1:samples - step); % Limitar el numero de muestras
```

Ouput_Variable

```
% Aqui se debe poner la variable de salida, si viniera en el Dataset
% Pero en este ejemplo, se lo genera al desfasar step muestras a la ravible pw_in
```

Raw data [Inputs_Variables Output_Variables]

```
% Raw data [Inputs_Variables Output_Variables]
rawdata = [pw_in pf_in vac_in vdc_in temp_in];
clear pw_in pf_in vac_in vdc_in temp_in
```

Paso 2: Preprocessing

Eliminar NAN

```
rawdata(isnan(rawdata)) = 0;  % eliminar todos los "not a number"
```

Eliminar outliers

```
preData = hampel(rawdata);
```

Graficar Raw data vs datos preprocesados

```
figure;

subplot(1,2,1)
% Graficar raw data
plot(t(1:samples - step,:),rawdata); % las 1k primeras filas
legend("pw-in", "pf-in", "vac-in", "vdc-in", "temp-in");
xlabel('Tiempo');
ylabel('Valores');
title('Raw data (sin preprocesar)');
```

```
grid on;

subplot(1,2,2)
% Graficar raw data
plot(t(1:samples - step,:),preData); % las 1k primeras filas
legend("pw-in", "pf-in", "vac-in", "vdc-in", "temp-in");
xlabel('Tiempo');
ylabel('Valores');
title('Datos preprocesados');
grid on;
```

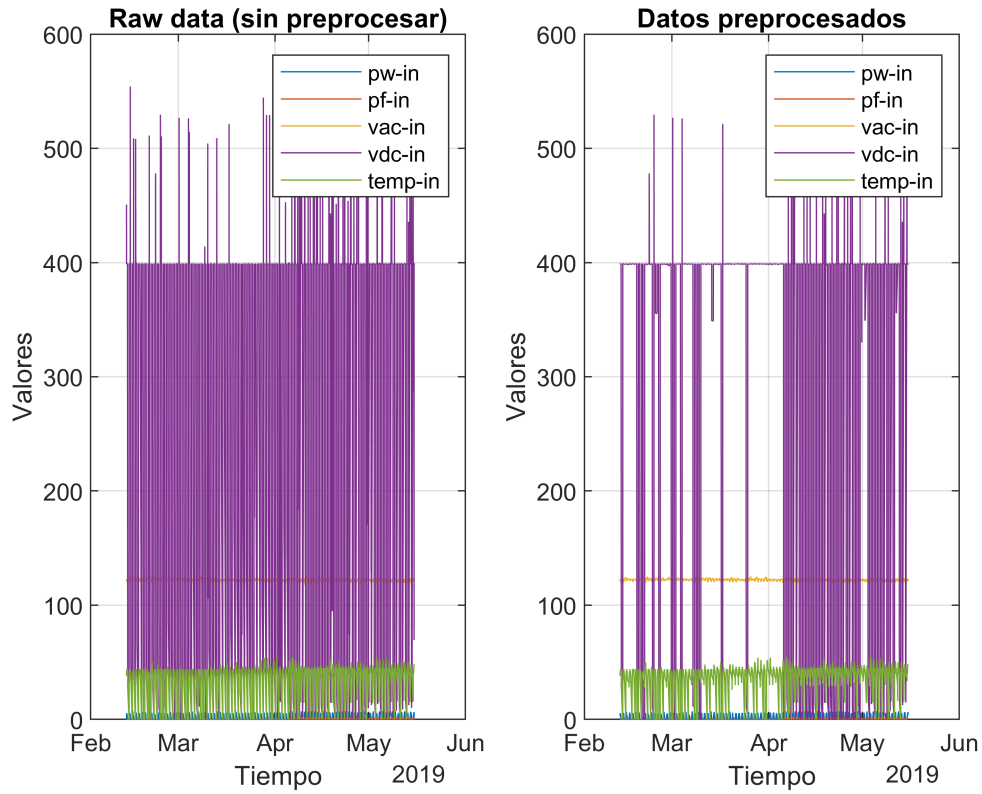

Paso 3: Feature extraction

```
DataIn=[];
for i=1:step:size(preData,1)-(step-1)
    feat = [mean(preData(i:i+step-1,:),1)];   %<=== mean features
    DataIn=[DataIn;feat];
end
```

Output_Variables

```
pw_predict = DataIn(2:end,1);
DataIn = [DataIn(1:end - 1, :)];
clear feat
```

Paso 4: Feture Selection

```
%Maximum correlation value allowed
% Dafault 0.70
threshold = 0.5;

% El numero de variables a analizar debe ser igual al numero de nombres de
% variables
varNames = {'mean_pw', 'mean_pf', 'mean_vac', 'mean_vdc', 'mean_temp'}; %<=== mean features

Features_labels=varNames;
corrcoef(DataIn)
```

```
ans = 5×5
    1.0000    0.2088   -0.3328    0.2701    0.5630
    0.2088    1.0000   -0.3271    0.2273    0.3404
   -0.3328   -0.3271    1.0000   -0.3030   -0.4167
    0.2701    0.2273   -0.3030    1.0000    0.3421
    0.5630    0.3404   -0.4167    0.3421    1.0000
```

```
[NewDataFeatures,NewFeaturesLabels,LabelsRemove] = Feature_Selection(DataIn,Features_labels,thr
```

```
NewDataFeatures = 2188×4
    4.0635         0  121.9491  399.0312
    4.8765         0  122.1405  398.9842
    5.2015         0  121.5275  398.6877
    4.7215         0  120.6757  398.6880
    3.3708         0  120.7853  398.9222
    2.7700         0  121.3435  398.9847
    1.3272         0  122.1560  398.7970
    0.0965         0  122.4882  306.5938
    0.0395         0  122.9727  140.7343
    0.4273         0  122.4963  398.6565
      ⋮
NewFeaturesLabels = 1×4 cell
'mean_pw'    'mean_pf'    'mean_vac'    'mean_vdc'
LabelsRemove = 1×1 cell array
    {'mean_temp'}
```

Paso 5: Dataset

Dividir el dataset en training_data y testing_data

```
training_data = [NewDataFeatures(1:round(end*0.7),:) ...
    pw_predict(1:round(end*0.7),:)]; % 70% de datos para entrenar
testing_data = [NewDataFeatures(round(end*0.7):end,:) ...
    pw_predict(round(end*0.7):end,:)];% 30% de datos para testing
```

Paso 6: Utilizar el toolbox **"regressionLearner"**

```
regressionLearner
```

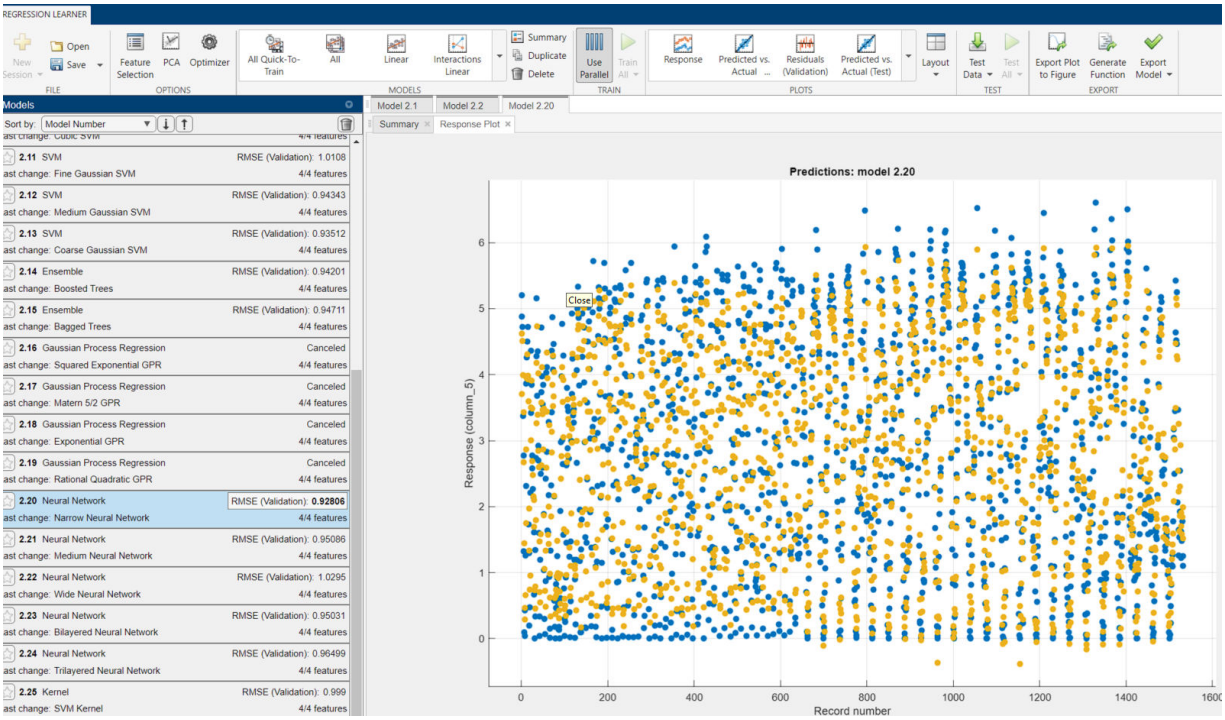

Paso 7: Hacer testing del modelo de forecasting

Simpre que el numero de features no cmabie, podemos usar esta misma funcion

```
[trainedModel, validationRMSE] = trainRegressionModel_narrow_NN(training_data)
```

```
trainedModel = struct with fields:
                predictFcn: @(x)neuralNetworkPredictFcn(predictorExtractionFcn(x))
    RegressionNeuralNetwork: [1×1 RegressionNeuralNetwork]
                      About: 'This struct is a trained model exported from Regression Learner R2022a.'
               HowToPredict: 'To make predictions on a new predictor column matrix, X, use: ↵  yfit = c.predictFcn(
validationRMSE = 0.9275
```

```
% hacer que el modelo haga la prediccion de pw
y_est = trainedModel.predictFcn(testing_data(:,1:end-1));
y_real = testing_data(:,end);
rmse = sqrt(mean((y_real - y_est).^2))
```

```
rmse = 0.8085
```

```
figure;
% Graficar testing del forecasting
plot(y_est); % las 1k primeras filas
hold on
plot(y_real); % las 1k primeras filas
```

```
hold off
legend("pw-est", "pw-real");
xlabel('Tiempo');
ylabel('Valores');
title('Y est vs real');
grid on;
```